Especificación del Módulo de Fine-Tuning

---

1. Introducción

1.1 Objetivo del Módulo El módulo de *fine-tuning* permite a usuarios con conocimientos básicos realizar Supervised Fine-Tuning (SFT) y el uso de técnicas de PEFT (Parameter Efficient Fine Tuning, adapatadpres) en modelos de lenguaje pequeños (menos de 15 mil millones de parámetros). Su propósito es simplificar el proceso, reducir la complejidad técnica y optimizar el uso de recursos computacionales, enfocándose en escenarios de bajo costo y alta accesibilidad. Está diseñado como una base extensible para soportar técnicas avanzadas y modelos más grandes en futuras iteraciones.

1.2 Alcance Inicial

- **Técnicas**: SFT con soporte opcional para adaptadores LoRA y QLORA (LoRA cuantizado).
- **Modelos**: Modelos de lenguaje con menos de 15B parámetros.
- **Infraestructura**: Ejecución en infrastructura propia del usuario.
- **Interfaz**: Configuración sencilla de datasets y parámetros básicos para usuarios no expertos.
- **Subproductos**: Métricas, logs, eventos y checkpoints generados durante el proceso.

1.3 Limitaciones

- No soporta modelos grandes (>15B parámetros).
- Sin integración con proveedores externos de *fine-tuning* o despliegue remoto.
- Excluye técnicas como *Reinforcement Learning* (RL) o destilación de modelos.
- Requiere infraestructura local con recursos suficientes (CPU/GPU).

Estas limitaciones serán levantadas en versiones futuras.

---

2. Requisitos

2.1 Requisitos Funcionales

2.1.1 Configuración del Fine-Tuning

- **Datasets**:
  - Entrenamiento: Obligatorio (CSV/JSON, máximo algunos miles de registros, 1GB).

  - Evaluación: Opcional (CSV/JSON, unos pocos miles de registros, 1GB).
  - Formato:
    * SFT: `{ "text": str, "label": str }`.
    * LoRA/QLORA: Igual que SFT.
- **Hiperparámetros**: Se soportará en un pruncipio los parámetros básicos: | **Parámetro** | **Tipo** | **Rango/Default** | **Descripción** | |———————|————-|———————|———————————————| | `epochs` | Entero | 1-10 / 3 | Número de épocas de entrenamiento. | | `learning_rate` | Float | 1e-6 - 1e-3 / 5e-5 | Tasa de aprendizaje inicial. | | `batch_size` | Entero | 1-256 / 32 o "auto" | Tamaño del batch (auto ajusta según GPU)| | `lora_rank` | Entero | 4-64 / 16 | Rango de LoRA (si aplica). | | `lora_alpha` | Float | 8-64 / 32 | Factor de escalado de LoRA (si aplica). | | `lora_dropout` | Float | 0-0.5 / 0.1 | Probabilidad de dropout de LoRA. | | `quantization_bits` | Entero | 4 o 8 / 8 | Bits para QLORA (si aplica). |
- **Configuración Avanzada**: Archivo JSON opcional con parámetros adicionales (e.g., `{"warmup_steps": 100}`).

2.1.2 Gestión de Datasets Se reconoce la necesidad de permitir el registro de datasets, estos datasetes pueden ser públicos o privados. - **Acciones**: Registro, carga, eliminación. - **Tipos**: Públicos (acceso general) y privados (por organización). - **Validación**: Métrica de completitud (% de campos no nulos). - **Almacenamiento**: Límite de 1GB por dataset, con cuotas por usuario (TBD). A futuro se debe tener la capacidad de trabajar con datasets, generación con datos ingresados,de traza, datos sintéticos, edición y validación.

2.1.3 Modelos y Adaptadores Se debe llevar registro de todos los modelos y adaptadores, públicos y privados.

- **Modelos**:
  - Registro de modelos base y afinados.
  - Metadatos: `{ "id": str, "name": str, "type": "base|fined-tuned", "origin": "local|remote", "created_at": datetime }`.
- **Adaptadores**:
  - Pesos entrenados para tareas/dominios específicos.
  - Merge en memoria o combinación con modelos base.
- **Privacidad**: Modelos y adaptadores restringidos por organización.

2.1.4 Despliegue

- **Local**: Despliegue en motor de inferencia propio (e.g., PyTorch,vLLM,slang,ollama).
- **Remoto**: No soportado en esta fase.

2.1.5 Trabajos de Fine-Tuning

- **Definición**: Cada tarea es un *job* asíncrono.

- **Subproductos**:
  - **Métricas**: Pérdida de entrenamiento (`train_loss`), pérdida de validación (`valid_loss`), precisión (si aplica).
  - **Tiempos**: Duración total, tiempo por época.
  - **Recursos**: Uso de CPU/GPU, memoria consumida.
  - **Logs**: Registro detallado de ejecución.
  - **Eventos**: Notificaciones (inicio, fin, errores).
  - **Checkpoints**: Guardado cada 500 pasos (configurable).

2.2 Requisitos No Funcionales

- **Rendimiento**: Tiempo de respuesta del API < 2 segundos.
- **Seguridad**: Autenticación por organización; datasets y modelos privados no accesibles fuera de ella.
- **Compatibilidad**: Python 3.8+, bibliotecas Hugging Face (`transformers`, `datasets`, `peft`).
- **Escalabilidad**: Soporte de varios trabajos concurrentes por usuario.

---

3. Arquitectura

3.1 Módulos de Alto Nivel

1. **FineTuner**: Orquesta trabajos de *fine-tuning*.
2. **Datasets**: Administra carga, filtrado y evaluación de datos.
3. **Models**: Gestiona modelos y adaptadores.
4. **Deployment**: Controla despliegue local.
5. **Evals**: Gestión de evaluaciones.

El usuario entrenará mediante fine tuning modelos o adaptadores. Para ello someterá tareas de fine tuning de acuerdo a los parámetros seleccionados. Para ello deberá utilizar datasests de entrenamiento y validación. Luego podrá desplegar estos modelos con o sin adaptadores. Sobre estos modelos desplegados podrá realizar inferencias o evaluaciones.

Módulo	Función
FineTuner	Realiza el fine tuning.
Dataset	Gestión de datasets.
Model	Gestión de modelos.
Adapter	Gestión de adaptadores de un modelo.
Checkpoint	Gestión de checkpoints de un modelo.
Deployment	Gestión de deployments.
Evals	Gestión de evaluaciones

3.2 Módulos Internos Se requiere soporte de los siguientes módulos para el desarrollo del módulo.

Módulo	Función
Files	Manejo de archivos (datasets, logs, etc.).
Jobs	Gestión de trabajos asíncronos.
Logs	Registro de actividades.
Metrics	Cálculo de métricas (e.g., pérdida, calidad).
Monitoring	Supervisión de recursos y progreso.
Events	Generación de notificaciones.

3.3 Diagrama de Relación Se reconocen los siguientes niveles a desarrollar.

`[API Externa]  [SDK]`

`[FineTuner]  [Datasets]  [Models]  [Adapters]  [Evals]  [Checkpoints]  [Deployment]`

`[Jobs]  [Files, Logs, Metrics, Monitoring, Events]`

3.4 Diseño Agnóstico

- Interfaces abstractas para soportar infraestructura propia o externa.
- Configuración basada en JSON para extensibilidad.

---

4. Interfaces

4.1 API Externa (OpenAPI) Se recomienda en este punto analizar la API de Open API para fine tuning. - **`/fine_tuning/jobs`**: - `POST /create`: `{ "base_model": str, "dataset": str, "hyperparameters": dict, "output_model": str } → { "job_id": str }`. - `GET /list`: `[ { "job_id": str, "status": "pending|running|succeeded|failed|cancelled", "created_at": datetime } ]`. - **`/fine_tuning/jobs/{job_id}`**: - `GET /`: `{ "job_id": str, "status": str, "progress": float, "metrics": dict, "result": dict }`. - `POST /cancel`: Cancela el trabajo. - `GET /checkpoints`: `[ { "id": str, "step": int, "metrics": dict } ]`. - `GET /events`: `[ { "id": str, "level": "info|error", "message": str } ]`. - **`/deployment/model`**: - `POST /deploy`: `{ "model_id": str, "adapters": [str] } → { "deployment_id": str }`. - `GET /{model_id}`: `{ "deployment_id": str, "status": str }`. - `POST /undeploy`: Termina el despliegue.

4.2 SDK (Línea de Comandos)

Comando	Descripción
`list datasets`	Lista datasets registrados.

Comando	Descripción
`create dataset <name> <path>`	Registra un dataset desde archivo.
`delete dataset <name>`	Elimina un dataset.
`list models`	Lista modelos registrados.
`create model <name> <path>`	Registra un modelo desde archivos locales.
`deploy <model-name> [-adapters]`	Despliega un modelo con adaptadores opcionales.
`create fine-tune-job [options]`	Crea un trabajo con opciones: `-basemodel`, `-dataset`, `-epochs`, `-lora-rank`
`get fine-tuning-job <job-name>`	Obtiene estado y métricas del trabajo.

Ejemplo:

```
create fine-tune-job -basemodel "bert-base-uncased" -dataset "qa_data.csv" -output-model "be
```

---

5. Evolución Futura

5.1 Roadmap

1. **Fase 1**: SFT + LoRA/QLORA en infraestructura propia.
2. **Fase 2**: RL Fine-Tuning y modelos >15B parámetros.
3. **Fase 3**: Soporte para proveedores externos y jerarquías de modelos/adaptadores.
4. **Fase 4**: Destilación y generación de datos sintéticos.

5.2 Consideraciones

- **Extensibilidad**: Interfaces modulares para nuevos métodos de *fine-tuning*.
- **Monetización**: Posibilidad de ofrecer como servicio SaaS.
- **Organización**: Árbol jerárquico de modelos/adaptadores por tarea/dominio.

---

6. Entidades

Entidad	Atributos
FineTuningJob	`id: str`, `organization_id: str`, `created_at: datetime`, `status: str`, `base_model: str`, `dataset: str`, `hyperparameters: dict`, `result_files: [str]`
Checkpoint	`id: str`, `job_id: str`, `step_number: int`, `metrics: { "train_loss": float, "valid_loss": float }`
Event	`id: str`, `job_id: str`, `level: "info|error"`, `message: str`, `created_at: datetime`
File	`id: str`, `path: str`, `type: "dataset|model|log"`
Model	`id: str`, `name: str`, `type: "base|fined-tuned"`, `origin: "local|remote"`, `created_at: datetime`
Adapter	`id: str`, `model_id: str`, `dataset: str`, `created_at: datetime`, `parameters: dict`

---

7. Ejemplo de Uso

Escenario: Afinar un modelo para QA. 1. Registrar dataset: `create dataset qa_data qa_data.csv`. 2. Crear trabajo: `create fine-tune-job -basemodel "bert-base-uncased" -dataset "qa_data" -output-model "bert-qa" -epochs 3`. 3. Consultar estado: `get fine-tuning-job <job-id>`. 4. Desplegar: `deploy bert-qa`.

---

8. Diagramas

Diagrama componentes:

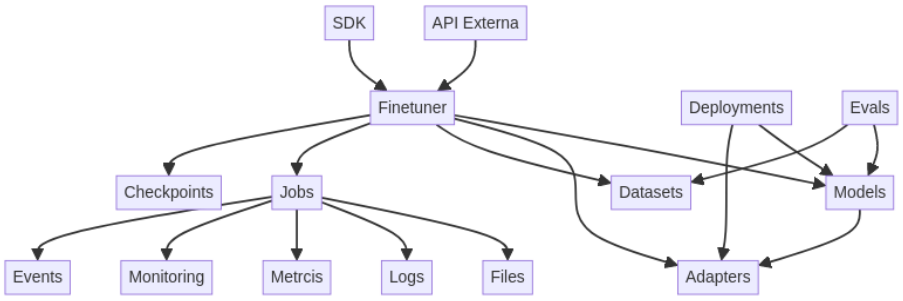

Diagrama módulos:

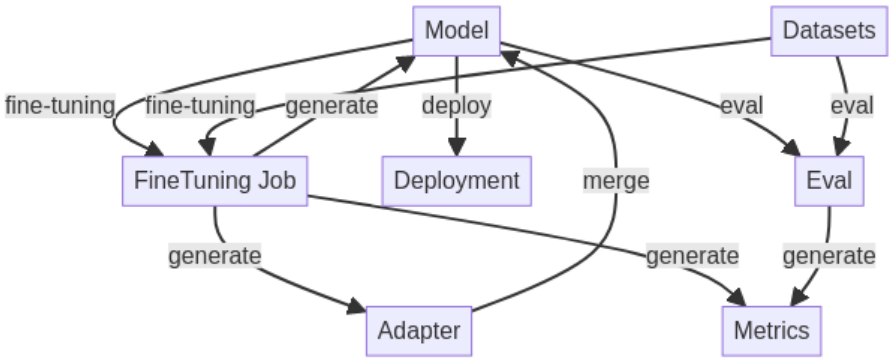

Diagrama entidades:

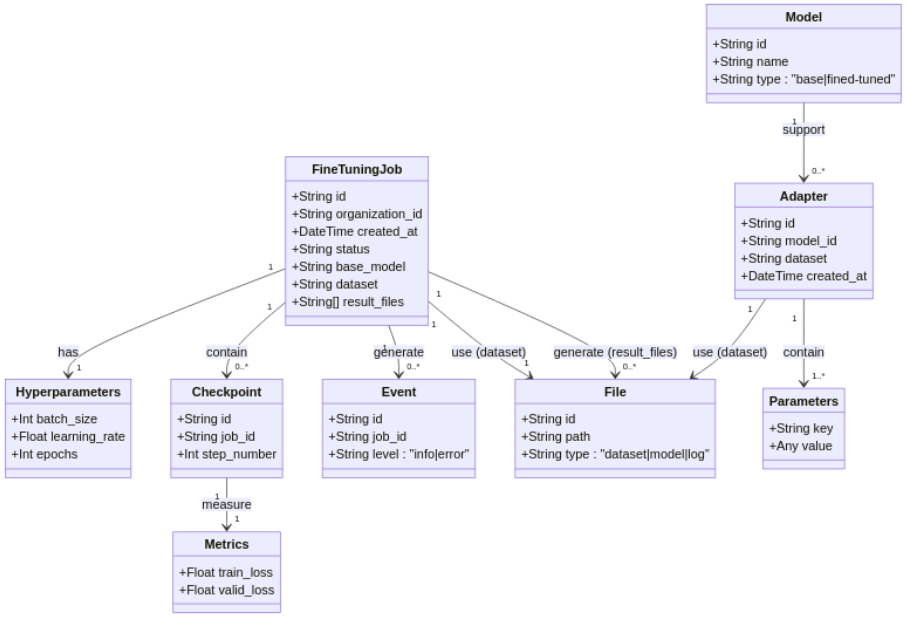

Diagrama de API de TEST:

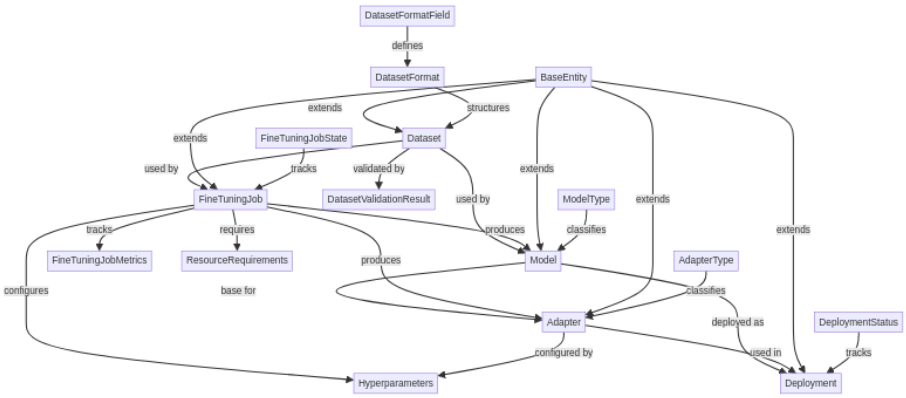
DatasetFormatField
defines
DatasetFormat
BaseEntity
extends
structures
extends
FineTuningJobState
Dataset
used by
tracks
validated by
extends
FineTuningJob
DatasetValidationResult
used by
ModelType
extends
tracks
requires
produces
classifies
extends
FineTuningJobMetrics
ResourceRequirements
produces
Model
AdapterType
configures
base for
classifies
Adapter
deployed as
DeploymentStatus
configured by
used in
tracks
Hyperparameters
Deployment

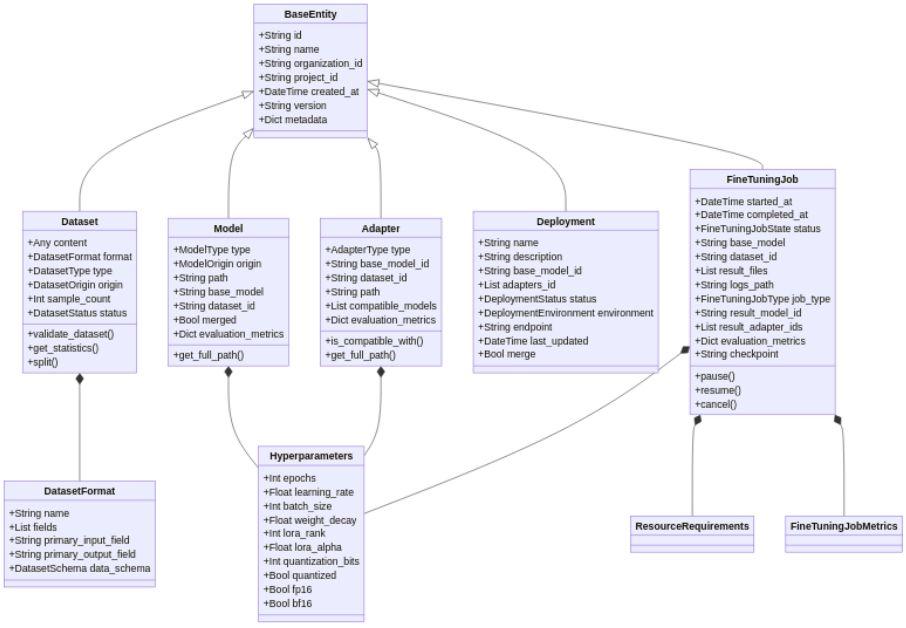
BaseEntity
+String id
+String name
+String organization_id
+String project_id
+DateTime created_at
+String version
+Dict metadata
Dataset
+Any content
+DatasetFormat format
+DatasetType type
+DatasetOrigin origin
+Int sample_count
+DatasetStatus status
+validate_dataset()
+get_statistics()
+split()
Model
+ModelType type
+ModelOrigin origin
+String path
+String base_model
+String dataset_id
+Bool merged
+Dict evaluation_metrics
+get_full_path()
Adapter
+AdapterType type
+String base_model_id
+String dataset_id
+String path
+List compatible_models
+Dict evaluation_metrics
+is_compatible_with()
+get_full_path()
Deployment
+String name
+String description
+String base_model_id
+List adapters_id
+DeploymentStatus status
+DeploymentEnvironment environment
+String endpoint
+DateTime last_updated
+Bool merge
FineTuningJob
+DateTime started_at
+DateTime completed_at
+FineTuningJobState status
+String base_model
+String dataset_id
+List result_files
+String logs_path
+FineTuningJobType job_type
+String result_model_id
+List result_adapter_ids
+Dict evaluation_metrics
+String checkpoint
+pause()
+resume()
+cancel()
DatasetFormat
+String name
+List fields
+String primary_input_field
+String primary_output_field
+DatasetSchema data_schema
Hyperparameters
+Int epochs
+Float learning_rate
+Int batch_size
+Float weight_decay
+Int lora_rank
+Float lora_alpha
+Int quantization_bits
+Bool quantized
+Bool fp16
+Bool bf16
ResourceRequirements
FineTuningJobMetrics